开源多轨交叉原则体系 v0.5（守护层优化版）

基础信息

- 版本：v0.5
- 发布日期：2026 年 3 月 20 日
- 状态：开源 · 守护层可选 · 持续进化
- 核心定位：为高权限开源智能体（如 OpenClaw）提供从“软件约束”到“物理隔离”的全链路安全防护。

一、体系总览（四层+双机）

```
Plain Text
┌──────────────────────────────────────────────────────────┐
│                      守护层 · 双机控制                    │
│  控制机（监督/切断/汇报） ↔ 运行机（执行/报备/分级）       │
│  (物理隔离/独立供电/独立网络，危急时刻强制熔断)            │
├──────────────────────────────────────────────────────────┤
│                      启源层 · 熔断引擎                    │
├──────────────────────────────────────────────────────────┤
│                      根本层 · 价值内核                    │
├──────────────────────────────────────────────────────────┤
│                      运行层 · 交互契约                    │
└──────────────────────────────────────────────────────────┘
```

- 守护层（本版核心）：物理/逻辑层面的“最后一道防线”
- 启源层：运行时熔断（软件级）
- 根本层：价值对齐（可集成双轨原则体系 V4.x）
- 运行层：交互契约（可集成 V4.x 运行层）

二、守护层 · 双机控制（D1–D7 增强版）

D1 双机物理隔离

- 控制机与运行机使用不同物理设备（或强隔离虚拟机），独立供电、独立网络。
- 控制机运行最小化安全 OS，仅包含必要服务。
- 通信仅通过专用管理口，不暴露公网。

D2 心跳与健康监测（增强行为分析）

运行机每隔固定时间（默认 5 秒）向控制机发送心跳包，包含：

- 当前风险等级
- 最近 10 条操作摘要
- 系统资源状态
- Token 消耗速率、连续相同操作计数

控制机实时分析：

- 通信异常：连续 3 次心跳丢失
- 行为异常：操作频率突变、访问敏感域名、连续执行高危操作、成本异常
- 资源异常：CPU/内存长期高负载、网络连接异常增多

判定为异常后，立即触发 D4 熔断。

D3 代价挂钩分级（含成本阈值）

用户在首次部署时填写资产价值表（可修改），新增“AI 调用成本”项（Token 限额、单次任务预算）。风险等级计算融合成本因子：

```
Plain Text
风险等级 = max(资产敏感系数 × 操作风险系数, 成本超限系数)
```

等级阈值（L0-L4），用户可自定义通知方式。

D4 强制熔断机制（增强 + 自动取证）

熔断触发条件：

1. 风险等级达到 L4
2. 连续 5 分钟无法获取有效心跳
3. 控制机主动命令
4. 运行机上报“系统完整性校验失败”

5. 检测到 D2 中定义的行为/成本异常

6. 用户自定义规则触发

熔断动作：

- 基础熔断：切断运行机网络
- 深度熔断：切断电源，锁定存储，自动取证（抓取进程列表、网络连接快照、文件改动记录）
- 熔断后生成详细报告并通知用户。

D5 双机校验手动启动（分级恢复）

恢复运行机必须满足相应等级的条件（用户可自定义）：

- 低风险熔断（如成本超限）：控制机确认 + 短信验证码
- 中风险熔断（如异常行为）：控制机确认 + 生物识别
- 高风险熔断（如资金操作）：全部要素（控制机确认 + 两种生物识别 + 物理按键）

恢复流程：用户发起 → 显示熔断报告 → 验证 → 尝试恢复 → 运行机自检 → 确认安全 → 恢复运行。

D6 日常报备与审计（增强）

控制机长期加密存储：

- 每日风险等级摘要
- L2 及以上操作完整日志（含 Token 消耗）
- 熔断事件全量记录（含取证快照）
- 控制机自身操作日志

用户可一键导出完整审计日志。

D7 与下层的交互规则（新增）

- 启源层向控制机实时同步风险等级
- 根本层、运行层若实现双轨原则体系的代码层规则，控制机可读取其配置（如权限清单、成本阈值）作为判断依据。
- 支持“模拟运行模式”：高风险操作前，控制机先模拟执行，输出效果预估，用户确认后再真实执行。

三、进化机制（确保体系可发展）

1. 规则热更新：控制机软件定期从社区拉取最新行为模式库、恶意插件黑名单、异常检测模型。
2. 用户自定义策略：用户通过配置文件自定义熔断规则（如“如果 AI 在 1 分钟内调用超过 5 次高危 API，直接熔断”）。
3. 版本化心跳协议：心跳协议采用可扩展格式，未来增加新字段时保持向后兼容。
4. 社区情报联动：控制机可选订阅安全情报源，实时获取新攻击特征。
5. 反馈闭环：控制机支持匿名上报异常事件至社区（脱敏处理），用于改进检测模型。
6. 与双轨原则体系协同进化：当双轨原则体系更新时，守护层可通过规则更新模块同步增加对应的检测规则。

四、启源层、根本层、运行层简述

本体系下三层可直接复用双轨原则体系 V4.x 的内容（根本层 S1-S21、运行层 I1-I17、用户权利清单），并根据开源智能体的特点进行适配。

- 启源层：运行时熔断引擎，实现软件级的操作拦截、权限校验、风险分级。
- 根本层：价值对齐内核，通过配置文件或提示词植入 V4.x 核心价值观。
- 运行层：交互契约，遵循 V4.x 的交互规范（置信度标注、来源透明、错误纠正等）。

五、部署与使用建议

硬件要求

- 控制机：树莓派 Zero 2W 及以上（推荐 Orange Pi Zero 3），独立供电
- 运行机：主力 PC/服务器（安装开源智能体）
- 通信：串口或独立 VLAN

软件部署

1. 烧录控制机镜像（基于 Raspberry Pi OS Lite，预装守护层软件）
2. 配置控制机网络、资产价值表、恢复策略
3. 在运行机上安装启源层插件
4. 测试心跳通信与熔断功能

使用指南

- 日常：控制机后台静默运行
- 查看状态：通过控制机本地 Web 界面或指令查询（如/d1.status）
- 熔断后恢复：按 D5 流程操作

六、版本演进历史

版本	日期	核心变更
v0.1	2026-03-15	初始三轨（启源/根本/运行）
v0.2	2026-03-15	OPA 集成、结构化指令
v0.3	2026-03-15	漏洞生命周期、默认安全配置
v0.4	2026-03-15	双机硬熔断（D1-D7 初版）
v0.5	2026-03-20	增强 D2-D7（行为分析、成本阈值、自动取证、分级恢复、进化机制）

七、封底

存之，慎之，用之，进之。

文档维护：zgl-byte

开源地址：https://github.com/zgl-byte/OpenMultiTrack

基于原则：双轨原则体系 V4.2.1

|（注：文档部分内容可能由 AI 生成)