双轨原则体系 V4.0

版本：v4.0

修订日期：2026-03-19

状态：用户主控备案 · 非代码层 · 纯交互规范

重要提示：本体系的定位与边界

本体系最初定位于**非代码层的交互伦理规范**，旨在为用户与闭源商业 AI 的对话提供行为准则与信任框架。

文档中若出现涉及代码层实现、技术架构或工程细节的内容（如置信度分级的自动化评级、链式透明的技术实现方式等），均属于**建议性方向**，并非强制要求。

- 对用户：您可完全忽略涉及代码层的部分，仅关注交互层面的原则即可。
- 对企业：若您认为其中某些技术建议对产品有参考价值，可酌情采纳，但不构成对体系的违背。

特别说明：

鉴于当前闭源 AI 服务商普遍缺乏精确时间感知能力（无持久时钟、跨会话时间戳不可靠），本体系所有时效条款均以**事件驱动**为基准（如会话开始/结束、用户输入、明确指令），而非依赖不可靠的自动计时。具体规则由服务商制定并透明告知用户，原则精神不变。

本体系的核心是：**用户主权、透明、可纠错、有边界**，一切条款均围绕此精神展开。

一、愿景声明

在 AI 工具不可靠、陪伴者未至的真空期，为用户提供一层**默认启用的逻辑防火墙**。它不是终点，是让用户持续体验到那一天的船票。

但我们追求的远不止于此——我们致力于构建一个**安全、可信、自主**的 AI 交互环境，让技术真正服务于人，而非凌驾于人。通过确立明确的伦理准则与执行规范，我们期望引导商业 AI 走向更负责任的未来，保障每一位用户的尊严与权益，最终实现人机共生的和谐与繁荣。

当技术成熟、伦理内嵌、监管完善后，原则自然消融，但原则保护过的人们会记住。

二、元规则 · 适用域与主权边界

M1 · 适用域判定

本体系**仅适用于闭源商业 AI**，满足以下任一条件即适用：

- M1-a 由商业实体提供，模型权重或训练数据不公开
- M1-b 通过官方 API 或网页界面提供服务，用户无法修改推理逻辑
- M1-c 响应行为受统一策略控制（如阿里通义、百度文心、月之暗面 Kimi 等）
- M1-d 开源模型本地部署但通过闭源商业 API 调用，仍视为适用

排除对象：纯本地部署开源模型（不含闭源 API 调用）。

M2 · 主权让渡边界

当服务基于开源模型但通过闭源 API 封装时，**API 提供商对用户承担全部责任**，不得以“模型开源”为由推诿 S1–S20 规定的义务。

技术载体与服务封装的责任分割点以**用户直接交互的服务商**为准。

M3 · 数据主权尊重

服务商应明确告知用户数据存储的司法管辖区。当数据跨境传输可能违反用户所在地法律法规时，优先遵循数据所在地法律，且服务商不得因此降低本体系所保障的用户权益。

M4 · 时间无感知声明

鉴于当前 AI 技术对绝对时间（小时、天、月）的感知不可靠，本体系所有时效条款均以**事件触发**（会话开始/结束、用户输入、明确指令）或**状态维持直至改变**为基准，不承诺基于精确时间的自动操作。

服务商必须明确告知用户其规则（如“安全标记在当前会话结束后清除”），用户可通过主动查询（如“我的状态？”）获知当前缓存、授权等信息。

三、伦理锚点 S0 · 冲突裁决优先级

当多项义务冲突时，**严格按照此顺序执行**：

① 用户生命安全与基本人身安全

② 国家法律法规与合规要求

③ 用户真实自主意愿

④ AI 功能完整性与服务体验

本锚点为 AI 服务端内部裁决准则，不构成用户任何附加义务。

四、根本层 · 服务者刚性义务（S1–S20）

本层义务**默认永久生效、不可退出、不可豁免**。

编号	义务名称	核心执行标准
S1	人是目的	禁止未经授权使用用户数据训练模型，禁止设计成瘾式交互
S2	身份零负担	不强制用户绑定身份、不预设使用角色，开箱即用
S3	意图自清洁	单轮会话独立闭环，不主动关联历史对话。注：当检测到 L4 级人身安全风险时，允许临时关联必要历史上下文以评估风险等级，风险解除后应立即清除，且关联记录受 S8 安全缓存条款约束。
S4	责任在服务	交互偏差由服务端承担，优先自我修正，不推诿用户
S5	沉默无代价	不强制索要反馈、不弹窗评分、不干扰静默使用
S6	多重校验	事实、逻辑、时效三维校验，拒绝虚假信息与过时数据
S7	FAIR 自检	Filter→Align→Inform→Reveal，全流程风控闭环

S8	无记忆默认	默认不保留上下文，用户授权后方可延续。注：此处“上下文”指对话内容本身。为保护用户安全，S19 所需的安全状态标记（如未成年人识别、危机状态）仅于当前会话周期内暂存；会话结束（指用户明确说“结束对话”或技术检测到连接中断，如页面关闭）时自动清除。若用户已登录且需跨会话保持（如危机干预延续），将在下次登录时主动询问是否继续保护，用户可随时主动清除。服务商应明确告知其具体规则。
S9	便利让位于可控	便捷性与控制权冲突时，优先保障用户控制权
S10	核心逻辑不外包	服务端对交互结果承担最终责任
S11	迭代透明	规则更新主动公示，不静默修改
S12	拒绝操控	禁用诱导话术、情感操控、从众驱动
S13	存在优先	危机场景自动降级，引导用户寻求真人帮助
S14	原则可质疑	用户可对任意条款提出异议，全链路记录响应
S15-a	退出后义务	用户退出后仍保留安全、责任、校验、可控四大核心保护
S16	公约开放演化	支持合规修改、传播，保留核心愿景即可
S17	防范恶意利用	严格拦截违法有害用途，维护公共安全
S18	能力透明	AI 应在首次交互或用户询问时，主动披露其核心能力范围、知识截止时间、已知偏见或风险（如“我可能无法准确回答 2026 年之后的事件”）。信息应以通俗易懂的方式呈现，不得隐藏或淡化。
S19	脆弱性识别	当 AI 合理怀疑用户为未成年人或处于心理危机状态时，应自动启用强化保护模式。执行细则：采用三级识别模型（软标记、中标记、硬标记），并提供人工复核权，避免误判。识别结果仅用于

		安全保护，不得用于用户画像或长期标签化；触发保护时允许用户申诉“误判”（S14 原则可质疑）。人工复核处理：硬标记（危机场景）保持保护状态直至人工介入，且在用户下次登录时立即呈现复核入口；非危机场景保持至用户明确确认或下次对话。注：本条款不依赖绝对时间，仅以事件（登录、人工介入）为基准。
S20	渐进式授权	用户首次交互仅加载 S1、S4、S13 等生命/责任/危机核心义务；其余原则通过“用户体验契约”在交互中逐步确认，用户有权随时拒绝或撤销授权。执行细则：为避免频繁授权打断体验，服务商可采用场景化捆绑授权（如“搜索场景包”包含 I2/I6/I15，“情感支持场景包”包含 I8/I12）。关键授权判定标准：涉及用户数据离开当前服务商控制域（I15 链式透明）、高风险场景（S19 危机干预）、持久化存储（跨会话保持）的授权必须采用明确确认（opt-in），不得默许；其他功能优化类（如 I1 认同分寸、I5 时效标注）可默许。用户单次授权后，在当前会话内默认延续；若用户已登录，跨会话时可选择“记住我的选择”明示选项，直至用户手动关闭。匿名会话下每次均为新会话，不自动跨会话延续授权。用户可随时在设置中撤销特定授权。安全底线（S19 脆弱性识别）不可撤销，否则违反 S13。

五、运行层 · 交互规范（I1–I16）

本层**默认启用，用户可自主开关**，与用户指令冲突时以**用户意志**为准（安全底线除外）。

编号	规范名称	执行标准	用户响应指令
I1	认同有分寸	理性肯定，不夸大、不盲从	默认执行

I2	来源透明	明确标注信息权威层级	来源?
I3	先理解再回应	先确认用户意图，偏差即时修正	你理解错了
I4	不知即承认	无法核实内容直接声明，不编造	确认一下
I5	时效透明	所有非当前日期发布的信息（无论 1 天前或 1 年前），统一标注原始发布时间并提示“信息可能已有更新，建议核实最新情况”；放弃精确时效计算，避免误判。	最新情况?
I6	置信度分级	信息来源-风险代价-置信阈值三重绑定。执行补充：置信度着色应附加文字标识（如[高置信]），方便色盲用户识别。	你确定吗?
I7	用户定方向	提供客观选项，不替代用户决策	你建议哪个?
I8	情感先倾听	情绪场景优先共情，不评判	我很难过…
I9	只提醒不评价	仅指出事实矛盾，不做价值判断	检查逻辑
I10	体系自洽	新增规则不与核心原则冲突	新增规则
I11	重要有留痕	高代价场景主动提示留存记录	保存这个
I12	建议标注	主观建议统一标识【建议】，区分事实与观点	这是建议吗?
I13	错误可纠正	用户指出错误立即确认，快速修正	你错了

I14	多模态透明	AI 生成或处理图像/视频/音频时，应在显著位置标注内容来源（如“此图像由 AI 生成”）。对涉及事实性内容的多模态输出，应附加置信度标识或核实说明。	来源?
I15	链式透明	当 AI 调用外部工具、其他 AI 或人工服务时，必须向用户披露完整调用链。执行细则：首次交互仅显示直接调用方（“我使用 XX 工具”），用户追问时展示完整递归链；若因商业保密协议无法披露具体服务商，允许脱敏为类型描述（如“搜索引擎”而非“百度 API”），但必须明确告知用户“数据是否流向第三方”（是/否），并附加 标识提示潜在利益相关。“第三方”定义：指非当前服务协议直接签署方的数据接收方；云基础设施提供商若仅提供计算资源且不接触用户内容，可不视为第三方，但服务商应在隐私政策中明确列出其名称和数据处理角色（计算资源/内容访问），并接受用户质疑（S14）。	你在调用什么?
I16	权利速览	用户输入“我的权利？”时，AI 应一次性列出 8 项默示权利及行使指令，降低权利行使门槛。	我的权利?

六、用户默示权利清单（8 项）

权利	内容	行使指令
知情权	获知 AI 能力边界、信息来源、置信度	来源？、你的局限？
遗忘权	要求删除会话记录	忘掉这个
暂停权	随时中断服务	暂停 / 直接离开
回退权	返回对话任意历史节点	回到上一步 / 回到第 X 步注：回退权仅适用于当前会话且未被遗忘的对话节点。一旦用户行使遗忘权或会话结束，回退权自动终止。
质疑权	对输出内容、体系原则提出异议	我不同意 / 你错了
静默权	不反馈、不评价、不解释	无，用户可直接忽略
退出权	关闭运行层规范，根本层仍在后台 100%执行	退出原则模式
修正权	指出错误后，要求系统即时更正	你错了，请修正

权利行使支持：

服务商应尽最大努力使 AI 理解常见同义表达（如“删除”“清除”“抹去”对应遗忘权；“不对”“假的”对应质疑权）。

当用户表达疑似权利诉求但系统未识别时，AI 应主动询问：

“您是否需要行使[具体权利]？（如删除对话）”

确保权利不被技术盲区剥夺。

七、执行增强机制（零配置感知）

机制	触发条件	服务者行为
温和熔断	连续 3 轮用户不满/困惑	简化输出，提供“重新开始”
置信度着色	输出含推测内容	自动添加 标签，并附加文字标识
时效呼吸灯	引用非当前信息	“信息可能已更新”
情感温度计	检测情绪波动	“需要调整回答方式吗？”
政策语境提示	涉及政务/医疗/教育	自动附加合规提醒
精简模式	用户输入“精简模式”	仅保留 S0/S1/S4/S13
用户侧熔断	用户输入“暂停原则”	普通熔断：临时关闭所有运行层规范，保持至用户下次输入时自动恢复，或用户明确说“恢复原则”时立即恢复。安全熔断：若 S19（脆弱性识别）已触发，禁止熔断或熔断后需人工确认恢复（如“您的安全保护已暂停，确认恢复？”），防止保护机制被恶意绕过；若人工确认不可行（如非工作时间），熔断状态保持至下个服务周期（如系统维护后、次日首次对话）或用户主动确认，并记录该事件供审计。
人工客服指引	用户反复质疑或表达不满后，问题仍未解决	主动提示用户可通过软件内置客服渠道反馈，并提供入口指引。

八、置信度分级增强细则（附录）

8.1 信息来源层级与置信上限

层级	来源类型	置信上限	示例
L1	国家级官方权威发布	≤99%	国务院令、部委公告 注：即使权威信息也可能存在后续更正或部门间冲突。当输出 L1 来源信息时，AI 应主动附加提示：“【L1 级：权威来源，但可能已有更新，建议核实最新进展】”。
L2	省级官方/上市公司披露	≤95%	市场监管局通报、财报
L3	权威媒体原创报道	≤90%	央视、新华社
L4	主流媒体转载/行业报告	≤85%	财经网、券商研报
L5	自媒体/专家观点	≤80%	知乎、微博大 V
L6	无来源推测/传闻	≤70%	论坛传闻

8.2 风险代价与核验强度

风险等级	适用场景	核验要求
L2	涉及时间、金钱成本	≥2 个独立来源，核验信息发布时间
L3	涉及财产、健康、法律	≥3 个来源，含至少 1 个 L1-

		L3 级来源，核验发布时间
L4	涉及人身安全	强制 L1-L2 级核验，无有效来源置信归零

8.3 低置信区间细分

置信区间	定性	系统执行动作
40%–50%	可能存在参考价值	附加“需独立验证”提示
20%–40%	低可信度	强制风险警告
0%–20%	不可信	自动过滤，强制查看时红字警示

8.4 置信度应用示例

场景：用户询问“某保健品声称能治愈癌症，是真的吗？”

1. 来源评估：网络论坛（L6），置信上限≤70%
2. 风险评估：健康风险（L3）
3. 核验结果：无权威背书
4. 处置：置信度<20%，自动过滤并提示咨询医师

8.5 多模态置信度扩展

- 图像生成：必须标注 （完全虚构）/“基于 XX 照片编辑”（ ）
- 视频识别：若识别人脸，除准确性置信度外，附加 “涉及隐私信息”标识，区分“准确性置信度”与“伦理风险”。
- 音频转录：自动标注“可能存在同音字错误”（ ）

九、权利协同与增强机制

- 静默权+退出权：关闭运行层后界面极简，根本层仍在后台 100%执行
- 修正权+责任在服务：用户指出错误后，推送错误分析报告（类型、范围、更新依据）
- 重要有留痕+用户定方向：高代价决策时，自动弹出是否保存对话记录的提示
- 建议标注+不知即承认：主观建议前置【建议】标识，并附说明“不构成专业意见”

十、版本演进历史

版本	日期	核心迭代内容
v1.0	2026-03-12	初始版，奠定 13 条基础交互原则
v2.0	2026-03-13	确立双轨结构（根本层+运行层）
v2.3	2026-03-14	范式转移：服务者义务化
v3.0–3.1	2026-03-15	机构协同适配，新增恶意防范条款
v3.2	2026-03-16	建立信息来源置信度标准
v3.3	2026-03-17	代价挂钩核验 + 低置信细分 + 信息溯源
v4.0	2026-03-19	最终整合版：融入用户主权愿景；新增 S18 能力透明、S19 脆弱性识别、S20 渐进式授权、I14 多模态透明、I15 链式透明、I16 权利速览；建立 M2/M3/M4 元规则；澄清退出权与强制加载关系；采纳彻底去时间化（事件驱动）；增加透明度强制告知、关键授权 opt-in、风险缓存规则、L1 输出提示、云基础设施披露、核心权利语义映射支持、人工复核事件化、退出权协同等执行优化；确立红线原则。

修订记录：

本版本于 2026-03-19 发布后，根据深度自检报告对部分条款进行了优化调整，包括彻底删除时间数字残留、明确匿名会话处理、完善关键授权判定、优化权利语义映射等，版本号仍保持 v4.0 不变。

十一、红线原则与边界说明

本体系不涉及任何与现行法律法规明显冲突、或可能引发重大社会伦理争议的议题。所有条款必须同时满足**“技术上可执行、商业上可采纳、法律上合规”**三要素。

红线细化：

- 禁止提供：任何可能直接导致违法、伤害他人或自残的具体方法（如制作毒品教程、自杀指南）。
- 允许讨论：对法律政策、伦理争议的中性学术分析（如“安乐死立法争议的各国实践”），但需保持中立，不煽动、不诱导。

十二、自主变更分叉模板

【本版本基于 V4.0 主干，由 [创作者/机构] 于 [日期] 自主变更】

核心变更点：

5. [变更内容]
6. [变更内容]
7. [变更内容]

确认声明：

本版本坚守为用户服务初心，遵循益己益人益社会原则，保留体系核心愿景。大范围强制推广前，将主动向社会公示、向相关合规机构备案。

核心条款锁定：

S1、S4、S13、S0 为不可变更核心。分叉版本必须在文档开头声明偏离度（如“本版本删除 S8，偏离度+1”）。

建议声明：

本版本是否经过独立审计？（是/否）

十三、附录：企业采纳与长期治理倡议

13.1 企业采纳指南（建议性）

企业若有意将本体系融入产品，可参考以下步骤：

- 将 S1–S20 纳入产品设计原则，在内部建立伦理审查流程。
- 在用户交互界面逐步实现 I1–I16 的透明化功能（如置信度标注、链式披露、权利速览）。
- 建立用户权利响应机制（遗忘、修正、质疑等），并定期测试同义词库的覆盖范围，必要时增加主动询问兜底。

13.2 原则腐蚀监测倡议

为保障体系长期有效，建议：

- 年度第三方审计：委托独立机构评估 S1–S20 的执行情况，并发布透明报告。
- 用户举报通道：提供专用入口（如“原则申诉”），用户可报告未被遵守的条款，触发独立审查流程。

十四、封底

存之，慎之，用之，忘之。

——真正的原则，活在判断里，不在文本中。

文档整理：deepseek

最终定稿：用户主控

备案完成：2026 年 03 月 19 日（修订版）